


TP557 - Tópicos avançados em IoT e Machine Learning: *Detecção de anomalias*





Inatel

Samuel Baraldi Mafra
samuelbmafra@inatel.br

Aprendizado não-supervisionado


- Diferentemente do aprendizado supervisionado, no aprendizado não-supervisionado, *não existem rótulos*.
- Esses algoritmos *descobrem padrões ocultos ou agrupamentos de dados* sem a necessidade de rótulos.
- São usados em problemas de
 - Segmentação
 - Agrupamento (i.e., *clusterização*)
 - Redução de dimensionalidade
 - *Detecção de anomalias*

Aprendizado supervisionado versus não supervisionado




Clusterização

- A forma mais simples e conhecida de aprendizado não-supervisionado é a clusterização ou agrupamento.
- O objetivo do agrupamento é *dividir os dados em vários grupos ou clusters*, de modo que as amostras dentro de cada grupo sejam *mais comparáveis entre si e diferentes das amostras dentro dos outros grupos*.
- É essencialmente um *agrupamento de amostras com base em quão semelhantes (ou próximos)* e diferentes elas são entre si.



K-means

- O algoritmo de clusterização mais conhecido é o K-means.
- O objetivo do K-means é simples: *agrupar amostras semelhantes* e descobrir padrões subjacentes.
 - Semelhante aqui é no sentido de *proximidade*.
- Para atingir este objetivo, o K-means procura um número fixo (k) de clusters em um conjunto de dados.



K-means

K-means pseudo-código

Entradas: conjunto de exemplos e número de clusters, k .

1. Defina k centroides iniciais (geralmente, feito de forma aleatória).

2. Repita

a) Calcule a distância de cada exemplo, x , para cada um dos k centroides e atribua cada exemplo ao cluster mais próximo.

b) Calcule o novo centroide de cada cluster*.


3. Enquanto as posições dos centroides continuarem mudando.

*os novos centroides são calculados como a média aritmética (centro geométrico) das amostras pertencentes a cada cluster.

K-means

Funcionamento do K-means


1. Define-se o número de clusters, $K = 3$



K-means

Funcionamento do K-means


2. Escolhe-se os centroides para cada cluster de forma aleatória.



K-means

Funcionamento do K-means


3. Atribui-se cada amostra ao centróide mais próximo com base na distância euclidiana.



K-means

Funcionamento do K-means


4. Recalcula-se o centroide dos clusters.



K-means

Funcionamento do K-means


5. Repete-se os passos 3 e 4.



K-means

Funcionamento do K-means

5. Repete-se os passos 3 e 4.




K-means

Funcionamento do K-means



Repete-se os passos 3-4 até que um dos casos abaixo ocorra:

1. A soma das distâncias entre as amostras e o centroide correspondente seja minimizada
2. Não haja alteração nos centroides
3. O número máximo de iterações seja atingido



Detecção de anomalias

- A detecção de anomalias é a identificação de itens, eventos ou observações raras que levantam suspeitas por diferirem significativamente da maioria dos dados.
- Exemplos
 - Detecção de spam
 - Detecção de fraude de cartão de crédito
 - Detecção de falhas em equipamentos
 - Detecção de movimentos anômalos



Detecção de anomalias

- Aplicações

Real world use cases of anomaly detection

Anomaly detection is influencing business decisions across verticals


TELECOM  Detect roaming abuse, revenue fraud, service disruptions	BANKING  Flag abnormally high purchases/deposits, detect cyber intrusions	FINANCE & INSURANCE  Detect and prevent out of pattern or fraudulent spend, travel expenses	HEALTHCARE  Detect fraud in claims and payments; events from RFID and mobiles	MANUFACTURING  Detect abnormal machine behavior to prevent cost overruns
TRANSPORTATION  Ensure external communications to the vehicle are not intrusion	SOCIAL MEDIA  Detect compromised accounts, bots that generate fake reviews	NETWORKING  Detect intrusion into networks, prevent theft of source code or IP	SMART HOUSE  Detect energy leakage, standardize smart sensor datasets	VIDEO SURVEILLANCE  Detect or track objects and persons of interest in monotonous footage

- Disrupção de serviços de telecom
- Compras fraudulentas
- Fraudes em pagamentos e pedidos de exames
- Comportamento anormal de máquinas
- Contas comprometidas
- Invasões em redes
- Vazamentos de água e energia
- Identificar objetos em imagens sem variação

Detecção de anomalias

- Algoritmos

- K-means usando a área do centroide
- Isolation Forest
- One-Class SVM
- Local Outlier Factor
- Etc.



K-means


- Exemplo: Escolha de Locais para centros de distribuição



[https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k means centros de distribuição.ipynb](https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k%20means%20centros%20de%20distribui%C3%A7%C3%A3o.ipynb)

K-means

Como escolher o K ótimo?



$$WSS = \sum_{i=1}^{N_c} \sum_{x \in C_i} d(x, \bar{x}_{C_i})^2$$

Detecção de anomalias

Movimentação de containers ao longo do ciclo logístico



Detecção de anomalias


Movimentação de containers ao longo do ciclo logístico

Classificação de 5 estados do container

- Parado
- Sendo erguido
- No mar
- No caminhão
- **Anomalia** (e.g., container caindo no mar, empilhadeira tombando)

Detecção de anomalias

Detecção de anomalias com K-means




https://colab.research.google.com/github/zz4fap/tp557-iot-ml/blob/main/examples/k_means_anomaly_detection.ipynb

Detecção de anomalias

Trabalho:


Incluir no Edge Impulse possíveis anomalias nos dados do ciclo logístico, e.g., quedas.



Detecção de anomalias

Trabalho:

Se baseie no seguinte tutorial: <https://docs.edgeimpulse.com/docs/tutorials/end-to-end-tutorials/time-series/continuous-motion-recognition>



Acompanhamento do trabalho final