


TP557 - Tópicos avançados em IoT e Machine Learning: *Identificação de palavras chave*




Inatel

Crédito: Marcelo Rovai-Unifei

Samuel Baraldi Mafra
samuelbmafra@inatel.br


Identificação de palavras chave

- A identificação de palavras-chave (do inglês, *key word spotting* - KWS) é uma técnica importante para aplicações de reconhecimento de fala.
- Ela permite aos usuários *ativar dispositivos falando uma palavra-chave*.




Identificação de palavras chave

- Aplicações: Identificação de vidro quebrado (segurança)




Identificação de palavras chave

- Aplicações: Detecção de anomalias (indústria)



Identificação de palavras chave

- Aplicações: detecção de ronco, tosse e choro.



Identificação de palavras chave

Desafios e restrições:

- Latência e largura de banda;
- Precisão e personalização;
- Segurança e privacidade;
- Bateria e memória.

Identificação de palavras chave

Desafios e restrições:

- Latência e largura de banda



- Latência: Os dispositivos devem responder rapidamente ao usuário, de preferência, em tempo real.
- Banda: Minimizar a quantidade de dados enviados através da rede, que é algo lento e caro.

Identificação de palavras chave

Desafios e restrições:

- Acurácia e personalização;



Accuracy & Personalization

- Acurácia: dispositivo deve ouvir o tempo todo, mas ser ativado no momento correto.
- Personalização: Ser ativado apenas com o(s) usuário(s) e não com ruído (ou outras pessoas).

Identificação de palavras chave

Desafios e restrições:

- Segurança e privacidade;



- Segurança e Privacidade: Proteger os dados que estão sendo enviados para a nuvem.
- Enviar para nuvem apenas os dados necessários e nada além disso!

Identificação de palavras chave

Desafios e restrições:

- Bateria e memória.




Battery & Memory

- Bateria: o consumo deve ser mínimo, pois os dispositivos são, em geral, alimentados por pequenas baterias.
- Memória: aplicações serão executadas em dispositivos com restrições de memória.


Identificação de palavras chave

Anatomia de uma aplicação de keyword spotting




Precisão e personalização;
Segurança e privacidade;
Bateria e memória.

Identificação de palavras chave



- Não é prático enviar dados o tempo todo para nuvem!
- Imaginem a Alexa fazendo isso o tempo todo.

Identificação de palavras chave



O KWS só liga o dispositivo no momento em que detecta a palavra chave, “filtrando” os dados enviados.

Identificação de palavras chave

E o dataset?

Identificação de palavras chave

Como construímos um bom conjunto de dados?

- Quem são os usuários?
 - Apenas jovens, mulheres, idosos ou público em geral?
 - De qual região?
- O que eles precisam?
 - Qual a tarefa sendo resolvida?
 - Quais palavras essa tarefa precisa que sejam identificadas?
- Como o mundo real torna isso difícil?
 - Ambiente fechado ou aberto?
 - Uma fábrica?
 - Ruído

Identificação de palavras chave

Como construímos um bom conjunto de dados?

- Quem são os usuários?
 - Apenas jovens, mulheres, idosos ou público em geral?
 - De qual região?
- O que eles precisam?
 - Qual a tarefa sendo resolvida?
 - Quais palavras essa tarefa precisa que sejam identificadas?
- Como o mundo real torna isso difícil?
 - Ambiente fechado ou aberto?
 - Uma fábrica?
 - Ruído

Existem alguns datasets disponíveis,
mas não são muitos...

Identificação de palavras chave

Speech Commands: A Dataset for Limited-Vocabulary Speech Recognition

Pete Warden
Google Brain
Mountain View, California
`petewarden@google.com`

<https://arxiv.org/pdf/1804.03209.pdf>

Identificação de palavras chave

Primeira versão contém exemplos de 10 palavras

- Yes
- No
- Left
- Right
- Go
- Stop
- One
- Two
- Four
- Six

Identificação de palavras chave

Segunda versão: 35 palavras

- 2618 voluntários
- Mais de mil gravações de cada palavra.

Word	Number of Utterances
Backward	1,664
Bed	2,014
Bird	2,064
Cat	2,031
Dog	2,128
Down	3,917
Eight	3,787
Five	4,052
Follow	1,579
Forward	1,557
Four	3,728
Go	3,880
Happy	2,054
House	2,113
Learn	1,575
Left	3,801
Marvin	2,100
Nine	3,934
No	3,941
Off	3,745
On	3,845
One	3,890
Right	3,778
Seven	3,998
Sheila	2,022
Six	3,860
Stop	3,872
Three	3,727
Tree	1,759
Two	3,880
Up	3,723
Visual	1,592
Wow	2,123
Yes	4,044
Zero	4,052

Identificação de palavras chave


Curadoria

- Verificação de palavras ditas de forma errada.
- Retirar ou normalizar gravações com volume baixo.
- Retirar momentos de silêncio.

Identificação de palavras chave

Mozilla common voice: crowdsourcing platform

- <https://commonvoice.mozilla.org/en>



Single Word Target Segment

A *speech commands-style*
dataset for **18 languages**

- “Yes” // “no”
- “hey” & “Firefox”
- **digits** 0-9

Identificação de palavras chave


Questões a serem levantadas para controle de qualidade

- Quais frequências devem ser gravadas?
 - Deve-se manter apenas o que nós conseguimos ouvir.
- Qualidade do microfone
- Ruído ambiente
 - Modelo treinado com um dataset gravado em um ambiente silencioso e inferência feita em ambiente ruidoso.

Identificação de palavras chave

Como será o pré-processamento
dos dados para entrada no
modelo?


Identificação de palavras chave




Identificação de palavras chave

Sinal de áudio

- 16 mil amostras capturadas por segundo
- **Não dá para usar como entrada de uma rede neural**




16kHz signal



Identificação de palavras chave





Sinal de áudio: palavras ligado e desligado

- Temos sinais contínuos, assim, onde a palavra começa?
- Como alinhar no início da palavra?
- Como extrair as partes importantes do sinal?



Identificação de palavras chave



Sinal de áudio YES/NO



Diferenças em intensidade

Identificação de palavras chave

Sinal de áudio ligado/desligado



A diferença entre esses áudios não é muito visível...


Identificação de palavras chave

O que podemos fazer?

Identificação de palavras chave

Sinal de áudio

- 16 mil amostras por segundo
- Aplicar FFT *à trechos* do sinal de áudio para extrair as componentes do sinal e criar um *espectrograma*.




Identificação de palavras chave

Sinal de áudio


- Espectrograma
- Um espectrograma é uma forma de visualizar a intensidade de um sinal através do *tempo e em várias frequências*.
- Os espectrogramas são *gráficos de duas dimensões* (frequência x tempo), com a *terceira dimensão*, a *amplitude*, sendo representada pela variação das cores.
- São criados aplicando-se FFT à trechos (i.e., janelas) do sinal.

Identificação de palavras chave




Aplica-se FFT à janela

Identificação de palavras chave




Move-se a janela e aplica-se a FFT à nova janela (pode haver sobreposição)

Identificação de palavras chave



Move-se a janela e aplica-se a FFT à nova janela





Identificação de palavras chave







A união de todas as FFTs forma o espectograma

Identificação de palavras chave


Sinal de áudio



Identificação de palavras chave




Identificação de palavras chave




Frequências mais baixas são muito mais nítidas para nós, ou seja, elas são menos atenuadas.

Identificação de palavras chave



Humanos *não percebem frequências linearmente*.
Somos *mais sensíveis às diferenças entre frequências mais baixas* do que
entre frequências mais altas.


Identificação de palavras chave



- A escala Mel é uma escala *perceptual*.
- Ela relaciona a *frequência percebida de um tom puro à sua frequência real* medida.
- Leva em conta que seres humanos são muito melhores em *discernir pequenas mudanças no tom em frequências baixas* do que em frequências altas.
 - Nosso ouvido não percebe todas as frequências igualmente.


Identificação de palavras chave

- Os bancos de filtros de Mel são aplicados ao espectrograma.
- Atenuam mais frequências mais altas.
- Esses filtros *ajudam a distinguir melhor as palavras* (imagem do espectrograma).
- O banco de filtros Mel aplica mais filtros nas faixas **onde o ouvido humano tem maior resolução**.





Identificação de palavras chave

- A maioria das informações linguísticas está concentrada nas faixas de frequência mais baixas, onde:
 - Os bancos de filtros Mel têm *maior densidade de filtros*.
 - Isso permite extrair *representações mais discriminativas da fala*.



Identificação de palavras chave

Espectrograma versus MFCC



Identificação de palavras chave


MFCC

- Uma Transformada Discreta de Cosseno é aplicada a cada banco de filtros para extrair coeficientes cepstrais.
- 13 coeficientes são, geralmente, mantidos, o restante é descartado, pois representam mudanças rápidas que não são úteis para reconhecimento de fala.

Identificação de palavras chave


Processo de classificação

A model for **Keyword Spotting**



Identificação de palavras chave

Processo de classificação



Identificação de palavras chave

Trabalho

- Pense em uma aplicação para identificação de palavras chave
- Elabore um detalhamento da aplicação
- Quais serão os comandos ou palavras chave?
- Plote os espectrogramas das palavras chave.
- Treine uma rede neural no edge impulse.
- Crie um power point com todos as informações.